# Estudi dels accidents de trànsit als Estats Units d'Amèrica Visualització de dades - Pràctica 2

#### Héctor Gutiérrez Muñoz

9 de juny, 2021

### Sumari

L	Càrrega del fitxer	1
2	Primera exploració	2
3	Preprocessament	2
1	Fitxer de sortida	5

# 1 Càrrega del fitxer

En primer lloc, carreguem els fitxers CSV. El dataset principal es pot trobar a https://www.kaggle.com/sobhanmoosavi/us-accidents. L'altre, de la població als Estats Units està disponible a https://www2.census.gov/programs-surveys/popest/tables/2010-2019/state/totals/nst-est2019-01.xlsx.

```
accidents_data <- read.csv("US_Accidents_Dec20_Updated.csv")

population_data <- data.frame(read_excel(
    path = "nst-est2019-01.xlsx",
    range = c("A10:M60"),
    col_names = FALSE))

## New names:
## * '' -> ...1
## * '' -> ...2
## * '' -> ...3
## * '' -> ...4
## * '' -> ...5
## * ...

# Només ens interessen dues columnes d'aquest dataset

population_data <- population_data[,c(1,13)]</pre>
```

colnames(population\_data) <- c("state", "population")</pre>

# 2 Primera exploració

Veiem uns exemples del primer dataset:

```
kable(
  t(head(accidents_data,2)),
  format = 'latex',
  booktabs = TRUE
) %>%
  kableExtra::kable_styling(latex_options = c("scale_down", "hold_position"))
```

També del segon:

```
kable(
  head(population_data),
  format = 'latex',
  booktabs = TRUE
) %>%
  kableExtra::kable_styling(latex_options = c("hold_position"))
```

# 3 Preprocessament

L'únic preprocessament que cal fer en aquest cas és fer el join dels dos datsets pel estat. Per fer-lo, primer s'han de posar les dues variables en el mateix format.

```
# Traiem el punt que hi ha a l'inici dels noms
population_data$state_trim <- substring(population_data$state, 2)

# Traiem la dada del Districte de Columbia, que no és a les variables state.abb
# i state.name de R

pop_DC <- population_data[population_data$state_trim == "District of Columbia", 2]

population_data <-
    population_data[-which(population_data$state_trim == "District of Columbia"),]

# Fem la conversió a abreviatures

population_data$state_abb <- state.abb[which(state.name == population_data$state_trim)]

# Tornem a introduir la dada del Districte de Columbia

population_data <- rbind(population_data, c("", pop_DC, "District of Columbia", "DC"))</pre>
```

Un cop fet això, podem fer el join:

	1	2
ID Severity Start_Time End_Time Start_Lat	A-1 2 2019-05-21 08:29:55 2019-05-21 09:29:40 34.80887	A-2 2 2019-10-07 17:43:09 2019-10-07 19:42:50 35.09008
Start_Lng End_Lat End_Lng Distance.mi. Description	-82.26916 34.80887 -82.26916 0 Accident on Tanner Rd at Pennbrooke Ln.	-80.74556 35.09008 -80.74556 0 Accident on Houston Branch Rd at Providence Branch Ln.
Number Street Side City County	439 Tanner Rd R Greenville Greenville	3299 Providence Branch Ln R Charlotte Mecklenburg
State Zipcode Country Timezone Airport_Code	SC 29607-6027 US US/Eastern KGMU	NC 28270-8560 US US/Eastern KEQY
Weather_Timestamp Temperature.F. Wind_Chill.F. Humidity Pressure.in.	2019-05-21 08:53:00 76 76 52 28.91	2019-10-07 17:53:00 76 76 62 29:30
Visibility.mi. Wind_Direction Wind_Speed.mph. Precipitation.in. Weather_Condition	10 N 7 0 Fair	10 VAR 3 0 Cloudy
Amenity Bump Crossing Give_Way Junction	False False False False False	False False False False False
No_Exit Railway Roundabout Station Stop	False False False False False	False False False False False False
Traffic_Calming Traffic_Signal Turning_Loop Sunrise_Sunset Civil_Twilight	False False False Day Day	False False False Day Day
Nautical_Twilight Astronomical_Twilight	Day Day	Day Day

state	population
.Alabama	4903185
.Alaska	731545
.Arizona	7278717
.Arkansas	3017804
.California	39512223
$. \\ Colorado$	5758736

#### by.y = "state\_abb")

### head(merged\_df)

```
##
                   ID Severity
                                         Start Time
                                                                End Time Start Lat
                             4 2017-09-22 21:46:42 2017-09-23 03:46:42
## 1
        ΑL
            A-639502
                                                                           33.68182
## 2
        AL A-2162021
                             3 2019-04-12 19:27:04 2019-04-12 20:56:46
                                                                           32.67388
## 3
        AL A-2813019
                             2 2017-12-11 07:59:43 2017-12-11 08:29:30
                                                                           33.51469
## 4
                             2 2020-11-13 01:54:00 2020-11-13 04:15:00
        AL A-855293
                                                                           32.46024
## 5
                             2 2017-09-15 18:42:52 2017-09-15 19:12:27
        AL A-1889735
                                                                           30.49452
                             2 2019-05-02 07:53:04 2019-05-02 09:07:54
## 6
        AL A-1018580
##
     Start Lng End Lat
                           End Lng Distance.mi.
## 1 -87.09209 33.67638 -87.07980
                                           0.800
## 2 -85.33090 32.67388 -85.33090
                                           0.000
## 3 -86.78768 33.51469 -86.78768
                                           0.000
## 4 -86.38945 32.46023 -86.38899
                                           0.027
## 5 -88.21700 30.49452 -88.21700
                                           0.000
##
  6 -88.11458 30.68940 -88.11458
                                           0.000
##
                                                                        Description
## 1
             Closed at CR-81/Sharon Blvd/Exit 78 - Road closed due to accident.
## 2
                                    Accident on I-85 Southbound at Exit 64 US-29.
## 3
                                                  Accident on 5th Ave at 30th St.
      Incident on COBBS FORD RD EB near I-65 Right lane blocked. Expect delays.
## 5 Accident on County Hwy-23 Padgett Switch Rd at County Hwy-24 Half Mile Rd.
## 6
                                              Accident on Dauphin St at Sage Ave.
##
                                                          Zipcode Country
                                                                             Timezone
     Number
                    Street Side
                                       City
                                               County
## 1
                    AL-4 E
                                                            35130
                                                                       US US/Central
        NaN
                              R.
                                    Quinton
                                               Walker
## 2
                    I-85 N
                                                                       US US/Central
        NaN
                              R
                                    Opelika
                                                  Lee
                                                            36801
## 3
       2999
                 5th Ave S
                              R Birmingham Jefferson 35233-2916
                                                                       US US/Central
## 4
        NaN Cobbs Ford Rd
                              R Prattville
                                               Elmore
                                                            36066
                                                                        US US/Central
## 5
              McDonald Rd
                                                                        US US/Central
        NaN
                              R
                                 Irvington
                                               Mobile
                                                            36544
## 6
               S Sage Ave
                              R
                                     Mobile
                                               Mobile
                                                            36606
                                                                        US US/Central
        NaN
##
     Airport Code
                     Weather Timestamp Temperature.F. Wind Chill.F.
                                                                      Humidity...
## 1
             KJFX 2017-09-22 21:55:00
                                                  71.6
                                                                  NaN
                                                                               100
## 2
                                                                   69
             KAUO 2019-04-12 19:56:00
                                                  69.0
                                                                                73
## 3
             KBHM 2017-12-11 07:53:00
                                                  37.0
                                                                  NaN
                                                                                82
## 4
             KMXF 2020-11-13 01:56:00
                                                  59.0
                                                                   59
                                                                               NaN
## 5
             KMOB 2017-09-15 18:56:00
                                                  79.0
                                                                                79
                                                                  NaN
##
             KBFM 2019-05-02 07:53:00
                                                  73.0
                                                                   73
     Pressure.in. Visibility.mi. Wind_Direction Wind_Speed.mph. Precipitation.in.
##
## 1
            30.00
                                3
                                             Calm
                                                               NaN
                                                                                  NaN
## 2
            29.18
                               10
                                                               0.0
                                             CALM
                                                                                    0
## 3
            30.24
                               10
                                             Calm
                                                               NaN
                                                                                  NaN
## 4
            29.87
                                              NNW
                                                               7.0
                                9
                                                                                    0
                                                               4.6
## 5
            29.97
                               10
                                               SE
                                                                                  NaN
## 6
            30.09
                               10
                                               NE
                                                               3.0
     Weather_Condition Amenity Bump Crossing Give_Way Junction No_Exit Railway
## 1
                          False False
                  Clear
                                          False
                                                   False
                                                             False
                                                                     False
                                                                              False
## 2
                  Fair
                          False False
                                          False
                                                   False
                                                             False
                                                                     False
                                                                              False
## 3
                  Clear
                          False False
                                          False
                                                   False
                                                             False
                                                                     False
                                                                              False
## 4
                          False False
                                                                     False
                 Cloudy
                                          False
                                                   False
                                                             False
                                                                              False
## 5
      Scattered Clouds
                          False False
                                          False
                                                   False
                                                             False
                                                                     False
                                                                              False
                          False False
## 6
                   Fair
                                          False
                                                   False
                                                             False
                                                                     False
                                                                              False
```

```
Roundabout Station Stop Traffic_Calming Traffic_Signal Turning_Loop
## 1
          False
                   False False
                                          False
                                                          False
                                                                        False
          False
                   False False
## 2
                                          False
                                                          False
                                                                        False
## 3
                   False False
                                          False
                                                          False
                                                                        False
          False
## 4
          False
                   False False
                                          False
                                                          False
                                                                        False
## 5
                   False False
          False
                                          False
                                                           True
                                                                        False
                   False False
          False
                                          False
                                                           True
                                                                        False
     Sunrise_Sunset Civil_Twilight Nautical_Twilight Astronomical_Twilight
##
## 1
              Night
                              Night
                                                  Night
                                                                         Night
                                                    Day
## 2
              Night
                                 Day
                                                                           Day
## 3
                 Day
                                 Day
                                                    Day
                                                                           Day
## 4
               Night
                              Night
                                                  Night
                                                                         Night
## 5
                 Day
                                 Day
                                                    Day
                                                                           Day
## 6
                 Day
                                 Day
                                                    Day
                                                                           Day
##
        state population state_trim
## 1 .Alabama
                  4903185
                              Alabama
## 2 .Alabama
                  4903185
                             Alabama
## 3 .Alabama
                  4903185
                             Alabama
## 4 .Alabama
                  4903185
                             Alabama
## 5 .Alabama
                  4903185
                             Alabama
## 6 .Alabama
                  4903185
                             Alabama
```

Es comprova que el join s'ha fet correctament i que el nombre de registres és el mateix que al dataset original:

```
dim(accidents_data)[1] == dim(merged_df)[1]
```

```
## [1] TRUE
```

Com que el dataset és força gran, en treurem les columnes que no es faran servir a la visualització per intentar millorar la performance.

```
merged_df <- merged_df[, c(
    "Severity", "Start_Time", "End_Time", "Start_Lat", "Start_Lng",
    "Distance.mi.", "State", "Temperature.F.", "Wind_Chill.F.", "Humidity...",
    "Pressure.in.", "Visibility.mi.", "Wind_Speed.mph.", "Precipitation.in.",
    "Weather_Condition", "Amenity", "Bump", "Crossing", "Give_Way", "Junction",
    "No_Exit", "Railway", "Roundabout", "Station", "Stop", "Traffic_Calming",
    "Traffic_Signal", "Turning_Loop", "Sunrise_Sunset", "population", "state_trim"
)]</pre>
```

Les dades de l'any 2016 no són força acurades, hi ha molts menys accidents que la resta d'anys. Per no desvirtuar l'anàlisi, traiem aquests registres del dataset.

```
merged_df <- merged_df[substring(merged_df$Start_Time,1,4) != "2016", ]</pre>
```

### 4 Fitxer de sortida

Finalment, les dades preprocessades es desaran a un fitxer.